

Ostbayerische Technische Hochschule Amberg-Weiden
Fakultät Elektrotechnik, Medien und Informatik

Prof. Dr. Ulrich Schäfer

Studiengang Bachelor Künstliche Intelligenz

Projektarbeit Natural Language Processing & Information
Retrieval

Tsvetan Stanchev

13. Januar 2026

Inhaltsverzeichnis

1	Einleitung	2
2	Projektplanung und Vorgehen	2
3	Implementierung	6
4	Probleme und Diskussion	8
5	Zusammenfassung und Ausblick	13
	Literatur	14

1 Einleitung

Question Answering (QA) ist eine zentrale Aufgabe der natürlichen Sprachverarbeitung und hat das Ziel, aus einem gegebenen Textkontext präzise Antworten auf natürlichsprachliche Fragen zu extrahieren oder zu generieren. Im Gegensatz zu klassischen Information-Retrieval-Systemen, die lediglich relevante Dokumente zurückliefern, erfordert QA ein tiefgehendes Sprachverständnis, da die Antwort häufig als spezifischer Textausschnitt im Kontext identifiziert werden muss. Solche Systeme finden Anwendung in zahlreichen Bereichen, darunter digitale Assistenzsysteme, Suchmaschinen, Wissensmanagement und automatisierte Auskunftssysteme.

Bis vor wenigen Jahren stellte das Fine-Tuning spezialisierter Transformer-Modelle auf aufgabenspezifischen Datensätzen den dominierenden Ansatz für Question Answering dar. Modelle wie BERT und seine Varianten werden dabei gezielt auf annotierten QA-Datensätzen trainiert, sodass sie lernen, relevante Antwortspannen innerhalb eines gegebenen Kontextes zu lokalisieren. Diese Methode hat sich insbesondere für klar definierte Aufgabenstellungen mit strukturierten Eingaben als sehr leistungsfähig erwiesen.

Mit dem Aufkommen von Large Language Models (LLMs) wie ChatGPT oder LLaMA-2 hat sich jedoch ein alternativer Ansatz etabliert. Anstatt Modelle aufgabenspezifisch zu trainieren, können diese großen, vortrainierten Sprachmodelle mittels sorgfältig formulierter Prompts dazu angeleitet werden, Fragen direkt auf Basis eines gegebenen Kontextes zu beantworten. Dieser Prompt-basierte Ansatz verspricht eine hohe Flexibilität, da kein zusätzliches Training erforderlich ist und ein einzelnes Modell für eine Vielzahl unterschiedlicher Aufgaben eingesetzt werden kann.

Ziel dieser Projektarbeit ist es, diese beiden Ansätze systematisch miteinander zu vergleichen. Dazu werden zwei fine-tuned Transformer-Modelle, DistilBERT und T5, sowie zwei Large Language Models, ChatGPT und LLaMA-2-7B-Chat, auf ihre Leistungsfähigkeit im Question Answering untersucht. Als Evaluationsgrundlage dient der SQuAD-Datensatz in Version 1.1, der einen etablierten Benchmark für extraktives Question Answering darstellt. Die Modelle werden anhand standardisierter Metriken, insbesondere Exact Match und F1-Score, bewertet, um sowohl die Genauigkeit als auch die inhaltliche Übereinstimmung der generierten Antworten zu erfassen.

Durch diesen Vergleich soll aufgezeigt werden, inwieweit fine-tuned Modelle gegenüber prompt-basierten Large Language Models weiterhin Vorteile bei spezialisierten Question-Answering-Aufgaben besitzen und welche Stärken und Schwächen sich aus den unterschiedlichen Modellansätzen ergeben.

2 Projektplanung und Vorgehen

2.1) Zielsetzung des Projekts

Ziel dieser Projektarbeit ist der Vergleich zweier Ansätze für Question Answering: speziell auf den SQuAD-Datensatz [3] fine-tuned Transformer-Modelle (DistilBERT,

T5) und große vortrainierte Large Language Models (ChatGPT, LLaMA-2-7B-Chat), die über geeignete Prompts gesteuert werden.

Untersucht wird, wie genau diese Modelle identische Kontext-Frage-Paare beantworten, gemessen anhand der Metriken Exact Match und F1-Score. Zusätzlich wird ein kleiner Testdatensatz mit 100 Fragen (TD-B) verwendet, um zu prüfen, ob er vergleichbare Aussagen wie der vollständige Validierungsdatensatz (TD-A) erlaubt und sich für den Vergleich mit LLMs eignet.

Damit soll ein fundierter Vergleich zwischen spezialisierten QA-Modellen und generischen Sprachmodellen ermöglicht werden.

2.2) Datensatz

Als Datengrundlage für diese Projektarbeit wird der Stanford Question Answering Dataset (SQuAD) Version 1 verwendet. SQuAD besteht aus Kontextpassagen aus Wikipedia-Artikeln sowie zugehörigen Fragen, deren Antworten als exakte Textspannen im jeweiligen Kontext annotiert sind. Der Datensatz ist ein etablierter Standard für die Evaluierung von Question-Answering-Systemen.

Für die Experimente werden zwei Testdatensätze definiert. Der vollständige offizielle Validierungsdatensatz von SQuAD wird als TD-A verwendet und dient zur umfassenden Evaluierung der fine-tuned Modelle DistilBERT und T5. Zusätzlich wird aus diesem Validierungsdatensatz ein zufälliger Teilstestdatensatz mit 100 Fragen erzeugt, der als TD-B bezeichnet wird.

TD-B wird verwendet, um sowohl die fine-tuned Modelle als auch die Large Language Models ChatGPT und LLaMA-2-7B-Chat unter identischen Bedingungen zu testen. Da die Auswertung der LLMs manuell beziehungsweise mit hohem Rechenaufwand erfolgt, ermöglicht TD-B einen fairen und praktikablen Vergleich aller Modelle. Gleichzeitig erlaubt der Vergleich der Ergebnisse von TD-A und TD-B eine Bewertung der Aussagekraft des kleinen Testdatensatzes.

2.3) Modelle

Für den Vergleich werden zwei fine-tuned Transformer-Modelle und zwei Large Language Models eingesetzt, die unterschiedliche Ansätze für Question Answering repräsentieren.

DistilBERT [4] ist ein kompaktes und effizientes Derivat des BERT-Modells, das speziell für extraktives Question Answering eingesetzt wird. Das Modell erhält einen Kontext und eine Frage als Eingabe und bestimmt die Antwort als zusammenhängende Textspanne innerhalb des Kontexts. Aufgrund seiner reduzierten Modellgröße eignet sich DistilBERT gut für effizientes Fine-Tuning und dient in dieser Arbeit als Vertreter klassischer, aufgabenspezifisch trainierter QA-Modelle.

T5 (Text-to-Text Transfer Transformer) [2] formuliert alle Aufgaben, einschließlich Question Answering, als Text-zu-Text-Problem. Im Gegensatz zu DistilBERT erzeugt T5 die Antwort generativ als neuen Text, anstatt sie direkt aus dem Kontext zu extrahieren. Dadurch kann das Modell flexibler formulieren, ist jedoch stärker von der

Qualität des Fine-Tunings und der Trainingsdaten abhängig.

Als Vertreter der Large Language Models wird ChatGPT [1] verwendet. ChatGPT ist ein leistungsfähiges, allgemein trainiertes Sprachmodell, das über ein Prompt dazu angeleitet wird, Fragen auf Basis eines gegebenen Kontexts zu beantworten. Da es nicht auf den SQuAD-Datensatz fine-tuned wurde, zeigt es, wie gut ein starkes generisches Sprachmodell ohne aufgabenspezifisches Training für Question Answering geeignet ist.

Zusätzlich wird LLaMA-2-7B-Chat [5] eingesetzt, ein frei verfügbares Large Language Model mit etwa sieben Milliarden Parametern, das für dialogbasierte Anwendungen optimiert ist. Auch dieses Modell wird ausschließlich über Prompts gesteuert und nicht weiter fine-tuned. Es dient als Vergleich zu ChatGPT, um zu untersuchen, wie sich ein offenes, lokal ausführbares LLM im Vergleich zu einem kommerziellen System verhält.

Durch diese Modellauswahl wird ein breites Spektrum von spezialisierten QA-Systemen bis hin zu generischen Sprachmodellen abgedeckt, was einen aussagekräftigen Vergleich der beiden Ansätze ermöglicht.

2.4) Trainingsstrategie für DistilBERT und T5

Die Modelle DistilBERT und T5 werden mithilfe des SQuAD-Trainingsdatensatzes fine-tuned, um sie gezielt für die Aufgabe des Question Answering zu optimieren. Beide Modelle werden aus vortrainierten Gewichten initialisiert und anschließend auf die spezifische Struktur von SQuAD angepasst, das aus Kontext-Frage-Antwort-Tripeln besteht.

Für das Fine-Tuning wird der offizielle Trainingssplit von SQuAD verwendet, während der Validierungsdatensatz als TD-A zur Leistungsbewertung während und nach dem Training dient. Die Modelle werden über mehrere Epochen trainiert, wobei nach jeder Epoche ein Modell-Checkpoint gespeichert wird. Auf diese Weise kann später der bestperformende Trainingsstand ausgewählt und für die Evaluation genutzt werden.

DistilBERT wird als extraktives Modell trainiert, das die Start- und Endposition der Antwortspanne im Kontext vorhersagt. T5 wird hingegen als generatives Modell trainiert, das auf Grundlage von Kontext und Frage eine Textantwort erzeugt. Trotz dieser unterschiedlichen Ausgabemechanismen werden beide Modelle auf denselben Trainingsdaten optimiert, wodurch ein fairer Vergleich ermöglicht wird.

Durch diese Trainingsstrategie wird sichergestellt, dass beide Transformer-Modelle bestmöglich an den SQuAD-Datensatz angepasst sind und ihre Leistung direkt mit den nicht fine-tuned Large Language Models verglichen werden kann.

2.5) Prompt-Design für LLMs

Da ChatGPT und LLaMA-2 nicht speziell auf den SQuAD-Datensatz fine-tuned sind, müssen sie über ein geeignetes Prompt explizit dazu angeleitet werden, die Aufgabe des Question Answering korrekt auszuführen. Ohne eine solche Instruktion neigen

Large Language Models dazu, erklärende Texte, Einleitungen oder frei formulierte Antworten zu erzeugen, die nicht mit dem Antwortformat von SQuAD kompatibel sind.

In dieser Arbeit wird ein festes Prompt-Template verwendet, das jedes Modell als reinen Antwort-Extraktor definiert. Das Prompt besteht aus drei zentralen Bestandteilen: dem Kontext, der die relevante Textpassage enthält, der Frage sowie einer klaren Instruktion, ausschließlich die exakte Antwortspanne aus dem Kontext zurückzugeben. Zusätzlich wird festgelegt, dass keine zusätzlichen Wörter ausgegeben werden dürfen und dass im Fall einer nicht auffindbaren Antwort der Platzhalter *unknown* zurückgegeben ist.

Dieses strikt formulierte Prompt soll sicherstellen, dass die Ausgaben der LLMs möglichst gut mit den goldstandardbasierten SQuAD-Antworten vergleichbar sind und eine automatische Berechnung von Exact-Match- und F1-Score möglich bleibt.

Für beide Large Language Models, ChatGPT und LLaMA-2-7B-Chat, wird derselbe Testdatensatz TD-B mit 100 Fragen verwendet. Die generierten Antworten werden für jedes Modell gespeichert und als JSON-Dateien abgelegt, sodass sie identisch wie die Ausgaben der fine-tuned Modelle ausgewertet und verglichen werden können.

2.6) Evaluationsstrategie

Die Leistung aller Modelle wird mithilfe der standardisierten Metriken Exact Match (EM) und F1-Score bewertet. Der Exact-Match-Wert misst, ob eine erzeugte Antwort exakt mit der Referenzantwort übereinstimmt, während der F1-Score auch teilweise korrekte Übereinstimmungen berücksichtigt. Durch die Kombination beider Metriken lassen sich sowohl strenge als auch tolerantere Bewertungsaspekte abdecken.

Für alle Modelle wird dasselbe Evaluierungsskript verwendet, um eine faire und konsistente Auswertung sicherzustellen. Die Ausgaben der Large Language Models werden vor der Bewertung nachbearbeitet, um zusätzliche Texte wie Einleitungen oder Erklärungen zu entfernen, sodass nur die eigentliche Antwortspanne mit den SQuAD-Referenzen verglichen wird.

2.7) Vergleichsdesign

Die beiden fine-tuned Modelle DistilBERT und T5 werden sowohl auf dem vollständigen Validierungsdatensatz TD-A als auch auf dem Teilstestdatensatz TD-B evaluiert. Die Large Language Models ChatGPT und LLaMA-2-7B-Chat werden ausschließlich auf TD-B getestet, da ihre Auswertung mit höherem manuellem oder rechnerischem Aufwand verbunden ist.

TD-B dient damit als gemeinsame Vergleichsbasis für alle vier Modelle. Gleichzeitig erlaubt der Vergleich der Ergebnisse der fine-tuned Modelle auf TD-A und TD-B eine Bewertung, inwieweit der kleine Datensatz TD-B repräsentativ für den vollständigen Testdatensatz ist und verlässliche Rückschlüsse auf die Modellleistung zulässt.

3 Implementierung

3.1) Datenvorbereitung

Die Grundlage aller Experimente bildet der SQuAD-v1-Datensatz, der im JSON-Format vorliegt und für jede Instanz einen Kontext, eine Frage sowie die zugehörige Referenzantwort enthält. Für die weitere Verarbeitung werden diese Daten zunächst eingelesen und in eine einheitliche interne Struktur überführt, bestehend aus Tripeln der Form (Kontext, Frage, Antwort).

Aus dem offiziellen Validierungsdatensatz wird der vollständige Testdatensatz TD-A erzeugt. Zusätzlich wird durch zufälliges Ziehen von 100 Einträgen aus TD-A der Teilstestdatensatz TD-B gebildet, der für den Vergleich mit den Large Language Models verwendet wird. Die zufällige Auswahl stellt sicher, dass TD-B eine möglichst unverzerrte Stichprobe des Gesamtdatensatzes darstellt.

Für die fine-tuned Modelle DistilBERT und T5 erfolgt anschließend eine Tokenisierung der Texte mithilfe der jeweils zugehörigen HuggingFace-Tokenizer. Dabei werden Kontext und Frage in ein gemeinsames Eingabeformat überführt, während die Antwort entweder als Textspanne (DistilBERT) oder als Zieltext (T5) kodiert wird. Durch diese Vorverarbeitung wird gewährleistet, dass alle Modelle konsistente und korrekt formatierte Eingaben erhalten und die Daten für Training und Evaluation vergleichbar bleiben.

3.2) Fine-Tuning der Transformer-Modelle DistilBERT und T5

Für das fine-tuned Question Answering werden die beiden Transformer-Modelle DistilBERT und T5 verwendet, die unterschiedliche Ansätze zur Antwortgenerierung verfolgen. DistilBERT wird als extraktives Modell eingesetzt und sagt die Start- und Endposition der Antwortspanne innerhalb des Kontexts voraus, während T5 als generatives Modell eine freie Textantwort aus Kontext und Frage erzeugt.

Beide Modelle werden aus vortrainierten Gewichten initialisiert und mithilfe des SQuAD-Trainingsdatensatzes weitertrainiert. Die Tokenisierung und Datenaufbereitung erfolgt modellabhängig, wobei Kontext und Frage gemeinsam als Eingabe verwendet werden. Das Training wird über mehrere Epochen durchgeführt, wobei nach jeder Epoche ein Modell-Checkpoint gespeichert wird. Dadurch können unterschiedliche Trainingsstände später ausgewählt und reproduzierbar ausgewertet werden.

Die Leistungsüberwachung erfolgt auf dem Validierungsdatensatz TD-A. Der jeweils bestperformende Checkpoint von DistilBERT und T5 wird anschließend für die abschließende Evaluation auf TD-A und TD-B verwendet, um einen fairen Vergleich mit den Large Language Models zu ermöglichen.

3.3) Inferenz mit Large Language Models ChatGPT und LLaMA-2

Für die Auswertung der Large Language Models werden die zuvor definierten Prompt-Templates verwendet, die Kontext, Frage und eine klare Instruktion zur Ausgabe der exakten Antwortspanne enthalten. Diese Prompts werden automatisch aus dem Testdatensatz TD-B generiert und bilden die Grundlage für die Inferenz beider LLMs.

Die Auswertung mit ChatGPT erfolgt über das Web-Interface. Die erzeugten Prompts werden schrittweise in die Benutzeroberfläche eingegeben, und die resultierenden Antworten werden manuell in strukturierter Form gespeichert. Dieses Vorgehen entspricht den Vorgaben der Aufgabenstellung, da für ChatGPT kein programmgesteuerter Zugriff zur Verfügung steht. Die gesammelten Ausgaben werden anschließend als JSON-Datei gespeichert, sodass sie automatisiert weiterverarbeitet werden können.

Für LLaMA-2-7B-Chat wird das Modell lokal auf einem Server mit GPU-Unterstützung geladen. Die Inferenz auf TD-B erfolgt vollständig automatisiert, indem alle generierten Prompts sequenziell an das Modell übergeben werden. Die Antworten werden direkt während der Berechnung in JSON-Dateien gespeichert. Durch diesen Ansatz ist eine effiziente und reproduzierbare Auswertung des Modells möglich.

Durch die gemeinsame Verwendung desselben Prompt-Formats und desselben Testdatensatzes TD-B ist sichergestellt, dass die Ergebnisse von ChatGPT und LLaMA-2 direkt vergleichbar sind.

3.4) Post-Processing

Die Ausgaben der Large Language Models müssen vor der Evaluation nachbearbeitet werden, da generische Sprachmodelle häufig zusätzliche Texte wie Einleitungen, Erklärungen oder Wiederholungen des Prompts erzeugen. Solche Zusätze sind für die automatische Berechnung der SQuAD-Metriken ungeeignet, da Exact Match und F1-Score ausschließlich auf der reinen Antwortspanne basieren.

Bei LLaMA-2 erfolgt diese Nachbearbeitung automatisiert. Nach der Textgenerierung wird der erzeugte Output so bereinigt, dass nur der eigentliche Antwortteil erhalten bleibt. Dazu wird beispielsweise alles vor der letzten Markierung „Answer:“ entfernt, und der Text wird an Zeilenumbrüchen oder unerwarteten Phrasen abgeschnitten. Auf diese Weise werden Prompt-Wiederholungen und zusätzliche Erklärungen entfernt, bevor die Antworten gespeichert und ausgewertet werden.

Bei ChatGPT wird die gewünschte Ausgabeform bereits durch das Prompt vorgegeben, das explizit die Rückgabe der exakten Antwortspanne ohne zusätzliche Wörter verlangt. Die Antworten werden anschließend in dieser Form manuell übernommen und gespeichert. Zusätzlich wird für alle Modelle, einschließlich DistilBERT und T5, eine Standard-Normalisierung angewendet, bei der Groß- und Kleinschreibung, Artikel, Satzzeichen und überflüssige Leerzeichen entfernt werden. Dadurch wird sichergestellt, dass die berechneten Exact-Match- und F1-Scores die inhaltliche Übereinstimmung der Antworten korrekt widerspiegeln.

3.5) Evaluationsskript

Die Bewertung aller Modelle erfolgt mithilfe eines einheitlichen Evaluationsskripts, das die Metriken Exact Match (EM) und F1-Score gemäß der offiziellen SQuAD-Definition berechnet. Für jede Frage wird die vorhergesagte Antwort mit einer oder mehreren Referenzantworten verglichen. Der Exact-Match-Wert ist 1, wenn die normalisierte Modellantwort exakt mit einer der Referenzantworten übereinstimmt, andernfalls 0. Der F1-Score wird auf Token-Ebene berechnet und misst die Überlappung

zwischen vorhergesagter und referenzierter Antwort.

Vor der Berechnung werden sowohl Vorhersagen als auch Referenzantworten normalisiert, indem Groß- und Kleinschreibung vereinheitlicht, Satzzeichen und Artikel entfernt sowie Leerzeichen standardisiert werden. Dadurch werden rein formale Unterschiede, die inhaltlich irrelevant sind, nicht als Fehler gewertet.

Das Evaluationsskript wird für alle Modelle identisch verwendet. Als Eingaben dienen die SQuAD-konformen JSON-Dateien des jeweiligen Testdatensatzes (TD-A oder TD-B) sowie die JSON-Dateien mit den Modellvorhersagen. Für DistilBERT und T5 werden die Vorhersagen direkt aus den Modellen erzeugt, während für ChatGPT und LLaMA-2 die zuvor gespeicherten Antwortdateien eingelesen werden. Durch diese einheitliche Auswertung wird ein fairer und vergleichbarer Vergleich aller vier Modelle gewährleistet.

4 Probleme und Diskussion

4.1) Fine-tuned Modelle vs. Large Language Models

Die Ergebnisse auf dem Teilstestdatensatz TD-B zeigen deutliche Unterschiede zwischen den spezialisierten, fine-tuned Question-Answering-Modellen und den allgemeinen Large Language Models. Wie in den Balkendiagrammen für F1-Score und Exact Match auf TD-B dargestellt, erzielt DistilBERT die besten Werte unter allen vier Modellen und übertrifft sowohl ChatGPT als auch LLaMA-2-7B-Chat. Insbesondere der hohe F1-Score von DistilBERT zeigt, dass das Modell sehr zuverlässig die relevanten Antwortspannen aus dem Kontext extrahiert.

	model	em	f1
0	DistilBERT	83.0	90.39
1	ChatGPT 5.2	77.0	88.01
2	T5	76.0	83.26
3	LLaMA-2-7B-Chat	68.0	74.96

Abbildung 1: TD-B: Vergleich der Modelle nach F1-Score und Exact Match.

Dieses Ergebnis verdeutlicht den Vorteil spezialisierter, aufgabenspezifisch trainierter Modelle. DistilBERT wurde direkt auf dem SQuAD-Datensatz fine-tuned und ist damit optimal auf die Struktur von Kontext-Frage-Antwort-Tripeln abgestimmt. Im Gegensatz dazu sind ChatGPT und LLaMA-2 generische Sprachmodelle, die nicht speziell für extraktives Question Answering trainiert wurden. Trotz ihrer hohen allgemeinen Sprachkompetenz fehlt ihnen die gezielte Optimierung auf die präzise Lokalisierung von Antwortspannen, was sich insbesondere im niedrigeren Exact-Match-Score widerspiegelt.




Abbildung 2: TD-B: Vergleich von F1-Score und Exact Match für alle vier Modelle mit Fokus auf die Unterschiede zwischen beiden Metriken.

Gleichzeitig zeigt ChatGPT eine bemerkenswert hohe Leistungsfähigkeit, insbesondere beim F1-Score, der nur geringfügig unter dem von DistilBERT liegt. Dies deutet darauf hin, dass ChatGPT in der Lage ist, inhaltlich sehr ähnliche Antworten zu generieren, selbst wenn diese nicht exakt mit den SQuAD-Referenzantworten übereinstimmen. Die Differenz zwischen F1 und Exact Match bei ChatGPT verdeutlicht dabei den generativen Charakter des Modells: Häufig werden korrekte Antworten paraphrasiert oder in leicht abgewandelter Form ausgegeben, was den EM-Wert reduziert, obwohl die inhaltliche Übereinstimmung hoch bleibt.

Insgesamt zeigen die Ergebnisse, dass fine-tuned QA-Modelle für strukturierte Benchmarks wie SQuAD weiterhin im Vorteil sind, während leistungsstarke Large Language Models wie ChatGPT inhaltlich konkurrenzfähig bleiben, jedoch durch ihre generative Natur bei strengen Metriken wie Exact Match benachteiligt werden.

4.2) Extraktives vs. generatives Question Answering

Die untersuchten Modelle unterscheiden sich grundlegend in der Art der Antwortgenerierung. DistilBERT arbeitet als extraktives Modell, das die Antwort als exakte Textspanne aus dem Kontext auswählt. T5, ChatGPT und LLaMA-2 sind hingegen generative Modelle, die Antworten in freier Textform erzeugen und dabei häufig paraphrasieren.

Diese Unterschiede wirken sich deutlich auf die Evaluierungsmetriken aus. Extraktive Modelle sind strukturell im Vorteil beim Exact-Match-Score, da ihre Ausgaben direkt mit den Referenzantworten übereinstimmen können. Generative Modelle erzielen hingegen oft einen hohen F1-Score, da ihre Antworten inhaltlich korrekt sind, aber in leicht veränderter Form vorliegen, was den Exact-Match-Wert reduziert.

Dies wird in den Fehleranalysen auf TD-B sichtbar, beispielsweise bei der Frage zur

Apollo-1-Katastrophe, bei der generative Modelle Varianten wie „O“ oder „Oxygen“ ausgeben, während DistilBERT die exakte Referenz „pure O“ extrahiert. Dadurch zeigt sich, dass generative Modelle inhaltlich konkurrenzfähig sind, aber durch die strengen SQuAD-Metriken benachteiligt werden.

4.3) TD-A vs. TD-B: Ist der Teilttestdatensatz repräsentativ?

Ein zentrales Ziel dieser Projektarbeit ist es zu untersuchen, ob der kleine Teilttestdatensatz TD-B mit nur 100 Fragen aussagekräftige Rückschlüsse auf das Verhalten der Modelle auf dem vollständigen Validierungsdatensatz TD-A erlaubt. Diese Frage ist entscheidend, da die Large Language Models ausschließlich auf TD-B evaluiert werden.

	model	em	f1
1	T5	76.93	85.57
0	DistilBERT	76.08	84.72

Abbildung 3: TD-A: Exact-Match- und F1-Scores der fine-tuned Modelle DistilBERT und T5 auf dem vollständigen Validierungsdatensatz.

Der Vergleich der beiden fine-tuned Modelle DistilBERT und T5 auf TD-A und TD-B zeigt jedoch, dass TD-B nicht vollständig repräsentativ ist. Auf dem vollständigen Datensatz TD-A erzielt T5 einen leicht höheren F1-Score als DistilBERT (85.57 vs. 84.72), was darauf hindeutet, dass T5 insgesamt etwas besser generalisiert. Auf TD-B kehrt sich dieses Verhältnis jedoch um: DistilBERT erreicht hier deutlich höhere Werte als T5 (90.39 vs. 83.26 F1), ebenso beim Exact-Match-Score.




Abbildung 4: Vergleich der fine-tuned Modelle DistilBERT und T5 auf TD-A und TD-B (Exact Match und F1-Score).

Diese Rangänderung ist in der Abbildung „Fine-tuned models: TD-A vs. TD-B (F1 and EM)“ klar sichtbar und zeigt, dass der kleine Testdatensatz eine verzerrte Stichprobe

darstellt. Offenbar enthält TD-B überdurchschnittlich viele Fragen, die gut zu den Stärken von DistilBERT passen, während T5 dort schlechter abschneidet als auf dem vollständigen Datensatz.

Damit lässt sich festhalten, dass TD-B zwar für einen praktischen Vergleich mit den Large Language Models notwendig ist, jedoch nur eingeschränkt als repräsentative Näherung für TD-A betrachtet werden kann. Die Ergebnisse auf TD-B müssen daher mit Vorsicht interpretiert werden, insbesondere wenn Modelle auf TD-A und TD-B unterschiedlich gerankt werden.

4.4) Übereinstimmung zwischen den Modellen

Neben den absoluten Leistungswerten ist auch interessant, wie ähnlich sich die Modelle in ihrem Antwortverhalten sind. Dazu wird auf TD-B eine paarweise Übereinstimmungsanalyse durchgeführt, bei der gemessen wird, wie oft zwei Modelle für dieselbe Frage nach Normalisierung exakt dieselbe Antwort liefern.

Die resultierende Übereinstimmungsmatrix zeigt, dass DistilBERT und T5 die höchste gegenseitige Übereinstimmung aufweisen. Dies ist zu erwarten, da beide Modelle auf demselben SQuAD-Datensatz fine-tuned wurden und daher ähnliche Antwortstrategien gelernt haben. Ihre Antworten stimmen deutlich häufiger überein als die Antworten der Large Language Models mit denen der fine-tuned Modelle.

Im Gegensatz dazu zeigen ChatGPT und LLaMA-2 eine geringere Übereinstimmung mit DistilBERT und T5. Dies deutet darauf hin, dass die LLMs die Fragen anders interpretieren oder alternative Formulierungen und Antwortspannen wählen. Besonders LLaMA-2 weicht häufig von den extraktiven Modellen ab, was mit seiner generativen und weniger stark auf SQuAD abgestimmten Natur erklärt werden kann.




Abbildung 5: Paarweise Übereinstimmung der Modellantworten.

Diese Analyse bestätigt, dass fine-tuned QA-Modelle ein konsistenteres und stärker standardisiertes Antwortverhalten zeigen, während Large Language Models größere Variabilität aufweisen. Dies trägt zusätzlich dazu bei, die Unterschiede zwischen spe-

zialisierten und generischen Modellen über reine F1- und EM-Werte hinaus sichtbar zu machen.

4.5) Antwortstil und Ausgabelänge

Die Modelle unterscheiden sich nicht nur in ihrer Genauigkeit, sondern auch in ihrem Antwortstil. Die Analyse der Antwortlängen auf TD-B zeigt, dass ChatGPT und LLaMA-2 im Durchschnitt längere und variablere Antworten erzeugen als die fine-tuned Modelle DistilBERT und T5. Dies ist eine Folge ihres generativen Charakters, bei dem Antworten häufig neu formuliert oder erweitert werden.




Abbildung 6: Verteilung der Antwortlängen auf TD-B für Large Language Models und fine-tuned Modelle.

Im Gegensatz dazu liefern die fine-tuned Modelle meist kurze und präzise Textspannen, die näher an den annotierten SQuAD-Antworten liegen. Dadurch sind sie insbesondere bei strengen Metriken wie Exact Match im Vorteil. Die Verteilung der Antwortlängen bestätigt somit die unterschiedlichen Eigenschaften von generativen und extraktiven Modellen im Question Answering.

4.6) Typische Fehlerfälle und schwierige Fragen

Die Analyse der schwierigsten Fragen in TD-B zeigt, dass bestimmte Fragestellungen selbst für leistungsstarke Modelle problematisch sind. Besonders auffällig ist, dass bei einigen Fragen alle vier Modelle versagen oder nur sehr geringe F1-Werte erzielen. Diese Fälle treten häufig auf, wenn die Antwort stark von der exakten Formulierung der Referenz abhängt oder mehrere semantisch ähnliche Varianten existieren.

Ein typisches Beispiel ist die Frage nach dem chemischen Element der Apollo-1-

Katastrophe. Während DistilBERT die Referenz „pure O“ korrekt extrahiert, geben die generativen Modelle Varianten wie „O“ oder „Oxygen“ aus. Obwohl diese Antworten inhaltlich korrekt sind, werden sie aufgrund der strengen SQuAD-Metriken als falsch oder nur teilweise korrekt bewertet. Ähnliche Effekte treten bei anderen Fragen auf, bei denen generative Modelle paraphrasieren oder zusätzliche Informationen einfügen.

Darüber hinaus zeigen einige Fragen, dass alle Modelle Schwierigkeiten haben, wenn die relevante Information im Kontext nur indirekt oder über mehrere Sätze verteilt enthalten ist. In solchen Fällen kommt es sowohl bei extraktiven als auch bei generativen Modellen zu Fehlzuordnungen oder unvollständigen Antworten. Diese Fehleranalyse verdeutlicht, dass die Grenzen der Modelle nicht nur durch ihre Architektur, sondern auch durch die Struktur und Eindeutigkeit der zugrunde liegenden Texte bestimmt werden.

4.7) Einschränkungen der Studie

Trotz der systematischen Auswertung unterliegen die Ergebnisse dieser Projektarbeit mehreren Einschränkungen. Eine zentrale Limitation ist die geringe Größe des Teildatensatzes TD-B, der nur 100 Fragen umfasst. Wie in der Analyse gezeigt wurde, ist TD-B nicht vollständig repräsentativ für den vollständigen Validierungssatz TD-A, was die Aussagekraft des Vergleichs mit den Large Language Models einschränkt.

Eine weitere Einschränkung betrifft die Nutzung von ChatGPT, dessen Auswertung aufgrund fehlender Programmierschnittstellen manuell über das Web-Interface erfolgen musste. Obwohl ein festes Prompt-Template verwendet wurde, kann dieser manuelle Prozess zu leichten Variationen oder Übertragungsfehlern führen.

Zudem reagieren Large Language Models empfindlich auf die genaue Formulierung des Prompts. Andere Prompt-Varianten hätten möglicherweise zu abweichenden Ergebnissen geführt, was die Vergleichbarkeit weiter beeinflussen kann. Schließlich wurden ChatGPT und LLaMA-2 nicht auf SQuAD fine-tuned, sondern ausschließlich im Zero-Shot-Prompting eingesetzt, was ihre Leistung im Vergleich zu den speziell trainierten Modellen grundsätzlich limitiert.

Diese Einschränkungen sollten bei der Interpretation der Ergebnisse berücksichtigt werden und zeigen zugleich Ansatzpunkte für zukünftige, umfassendere Untersuchungen auf.

5 Zusammenfassung und Ausblick

In dieser Projektarbeit wurde ein Vergleich zwischen fine-tuned Transformer-Modellen und Large Language Models für die Aufgabe des Question Answering auf dem SQuAD-Datensatz durchgeführt. Die beiden spezialisierten Modelle DistilBERT und T5 wurden auf SQuAD fine-tuned und auf dem vollständigen Validierungssatz TD-A sowie auf einem kleineren Teildatensatz TD-B evaluiert. ChatGPT und

LLaMA-2-7B-Chat wurden mithilfe eines festen Prompt-Templates ausschließlich auf TD-B getestet.

Die Ergebnisse zeigen, dass das fine-tuned Modell DistilBERT auf TD-B die beste Leistung erzielt und beide Large Language Models übertrifft. ChatGPT erreicht jedoch einen vergleichbaren F1-Score, was auf eine hohe inhaltliche Qualität seiner generierten Antworten hinweist, auch wenn diese aufgrund von Paraphrasierungen häufiger beim Exact-Match-Score benachteiligt werden. Der Vergleich von TD-A und TD-B hat zudem gezeigt, dass der kleine Teilstestdatensatz nicht vollständig repräsentativ ist, da sich die Rangfolge der fine-tuned Modelle zwischen beiden Datensätzen ändert.

Für zukünftige Arbeiten wäre es sinnvoll, größere und mehrere zufällige Teilstestdatensätze zu verwenden, um robustere Aussagen über die Leistungsfähigkeit der Modelle zu ermöglichen. Zudem könnte eine systematische Untersuchung unterschiedlicher Prompt-Varianten für Large Language Models durchgeführt werden. Schließlich wäre auch ein Fine-Tuning von LLMs auf SQuAD oder ähnlichen Datensätzen ein interessanter Ansatz, um den Leistungsunterschied zwischen spezialisierten und generischen Modellen weiter zu untersuchen.

Literatur

- [1] OPENAI: *ChatGPT: Optimizing Language Models for Dialogue*. Technical report, 2023
- [2] RAFFEL, Colin ; SHAZEER, Noam ; ROBERTS, Adam ; LEE, Katherine ; NARANG, Sharan ; MATENA, Michael ; ZHOU, Yanqi ; LI, Wei ; LIU, Peter J.: Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. In: *Journal of Machine Learning Research* 21 (2020), Nr. 140, S. 1–67
- [3] RAJPURKAR, Pranav ; ZHANG, Jian ; LOPYREV, Konstantin ; LIANG, Percy: SQuAD: 100,000+ Questions for Machine Comprehension of Text. In: *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2016
- [4] SANH, Victor ; DEBUT, Lysandre ; CHAUMOND, Julien ; WOLF, Thomas: DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. In: *Proceedings of the 5th Workshop on Energy Efficient Machine Learning and Cognitive Computing*, 2019
- [5] TOUVRON, Hugo ; MARTIN, Louis ; STONE, Kevin ; ALBERT, Peter ; ALMAHAIRI, Amjad u. a.: *Llama 2: Open Foundation and Fine-Tuned Chat Models*. arXiv preprint, 2023